

הגשה	לפי המועד הקבוע במודל
אופן עבודה	יחידים
פורמט הגשה	מחברת Jupyter / Colab + דו"ח קצר בפורמט PDF
משקל	חלק מרכיב המטלות בקורס (35% בסך הכל)

הרעיון המרכזי - במטלה זו אינכם "משתמשים" במודל בלבד - אתם חוקרים אותו כקופסה שחורה. כל טענה על המודל חייבת להיות מגובה בניסוי, במדידה ובניתוח.

1. מטרת המטלה

מטרת המטלה היא לחבר באופן יישומי בין הנושאים שנלמדו בתחילת הקורס: טוקניזציה, ארכיטקטורת Transformer, סוגי מודלים, מידע מיקומי והקשר, דקודינג, יעילות הסקה, סקיילינג והתנהגות של מודלי יסוד. במקום לממש רכיבים מאפס, תבצעו סדרת ניסויים מבוקרים על מודלים קיימים ותסיקו מהם מסקנות לגבי האופן שבו המודל פועל.

בסיום המטלה עליכם להיות מסוגלים לענות על השאלה: "מה ניתן ללמוד על מודל יסוד מתוך ההתנהגות שלו, מהמדידות שלו ומהמגבלות שלו?".

2. תרחיש העבודה: LLM Forensics

דמיינו שקיבלתם גישה למודל שפה כאל "ראיה" במעבדה. אינכם מסתפקים בשם המודל או בכרטיס המודל שלו. תפקידכם לבנות פרופיל פורנזי שלו באמצעות ניסויים.

- כל מסקנה חייבת להישען על לפחות תצפית אחת מדידה או דוגמה משכנעת.
- יש להפריד בין עובדה ידועה מתיעוד המודל לבין מסקנה שהסקתם מהניסוי.
- בכל ניסוי יש לשנות גורם אחד ככל האפשר, כדי לאפשר הסקת מסקנות סבירה.
- יש לשמור על reproducibility: seed, גרסת מודל, פרמטרי generation והקוד צריכים להיות מתועדים.

3. בחירת המודלים

בחרו משפחת מודלי LLM פתוחה אחת שבה קיימים לפחות שני גדלים שונים, לדוגמה Qwen, Gemma, Llama או משפחה דומה הזמינה בסביבת העבודה שלכם. מומלץ לבחור מודלים שניתנים להרצה ב-Colab או בסביבה מקומית סבירה.

העבודה תבוצע על שני מודלים לפחות מאותה משפחה: מודל קטן ומודל גדול יותר. חלק מהניסויים יבוצעו על שניהם, וחלקם יכולים להתבצע על אחד מהם בלבד בהתאם לדרישות.

הערה חשובה - אין צורך להשתמש במודל מסחרי בתשלום. עדיפות למודל פתוח שניתן לטעון דרך Hugging Face או סביבת עבודה דומה.

4. חלק א' - טביעת האצבע של ה-Tokenizer

מטרת החלק: לבדוק כיצד אותו תוכן מיוצג כרצף טוקנים, וכיצד בחירת tokenizer משפיעה על אורך הקלט ועל יעילות העבודה.

- 1) בחרו לפחות 12 קלטים קצרים הכוללים שילוב של עברית, אנגלית, מספרים, תאריך, כתובת URL, emoji, קוד קצר ומונחים טכניים.
- 2) הציגו עבור כל קלט את מספר הטוקנים ואת הפירוק לטוקנים עבור שני המודלים, או עבור שני tokenizers שונים אם שני המודלים חולקים tokenizer זהה.
- 3) בחרו לפחות שלוש תופעות מעניינות והסבירו אותן: למשל מילה עברית שמתפצלת להרבה טוקנים, מספר שמתפצל באופן לא צפוי, או קוד שמיוצג ביעילות.
- 4) חשבו "tokenization efficiency" פשוטה: מספר טוקנים / מספר טוקנים עבור כמה סוגי קלט, והשוו בין עברית לאנגלית.

נדרש בדו"ח: טבלה קצרה + 3–5 מסקנות. אל תסתפקו בצילומי מסך.

5. חלק ב' - דקודינג: מאותה התפלגות לתשובות שונות

מטרת החלק: להמחיש שהמודל מייצר התפלגות על הטוקן הבא, ושבחירת אסטרטגיית הדקודינג משנה את הפלט גם כאשר המודל וה-prompt זהים.

- 1) בחרו שתי משימות: אחת עובדתית/דטרמיניסטית יחסית ואחת יצירתית או פתוחה.
- 2) הריצו כל משימה עם לפחות ארבע תצורות generation שונות, למשל greedy, temperature, נמוך, temperature גבוה, top-p או top-k.
- 3) לכל תצורה בצעו לפחות חמש הרצות כאשר יש דגימה אקראית.
- 4) השוו עקביות, שונות, איכות, שיעור שגיאות ואורך תשובה. הגדירו מראש כיצד אתם מודדים לפחות שניים מהממדים הללו.

שאלת ניתוח: באילו משימות randomness מועיל, ובאילו הוא פוגע? קשרו את התשובה למנגנון next-token prediction ולא רק ל-"המודל יצירתי יותר".

6. חלק ג' - הקשר, מיקום והזיכרון של המודל

מטרת החלק: לחקור כיצד אורך ומיקום מידע בתוך חלון ההקשר משפיעים על היכולת להשתמש בו.

- 1) צרו מסמך סינתטי ארוך המכיל "עובדת מטרה" אחת ברורה, למשל קוד סודי, שם פרויקט או ערך מספרי.
- 2) מקמו את העובדה בשלושה מקומות שונים: בתחילת המסמך, באמצע ובסוף. השאירו את שאר התוכן זהה ככל האפשר.
- 3) הריצו את הניסוי בשלושה אורכי הקשר שונים לפחות, במסגרת המגבלות של המודל והחומרה.
- 4) מדדו האם המודל החזיר את העובדה הנכונה, את זמן ההסקה ואת מספר טוקני הקלט.
- 5) בוונוס: אם הסביבה מאפשרת, בדקו גם "lost in the middle" בעזרת מספר עובדות מתחרות.

שאלת ניתוח: מה אתם יכולים להסיק על השימוש של המודל בהקשר? מה לא ניתן להסיק מהניסוי לבדו לגבי RoPE או מנגנון המיקום הפנימי?

7. חלק ד' - סקילינג: מה משתנה כשמגדילים את המודל?

מטרת החלק: להשוות באופן אמפירי בין שני גדלים של אותה משפחת מודלים, תוך בחינת איכות מול עלות חישובית.

- 1) בנו benchmark קטן של 20-30 פריטים משלושה סוגים לפחות: הבנת הוראה, reasoning קצר, קוד/חישוב, עברית או משימת ידע פשוטה.
 - 2) הריצו את אותו benchmark על המודל הקטן ועל המודל הגדול באותם תנאים ככל האפשר.
 - 3) הגדירו metric פשוט וברור לכל סוג משימה: exact match, accuracy, unit tests, rubric ידני או שילוב ביניהם.
 - 4) השוו לפחות: איכות, זמן ריצה ממוצע לדוגמה ושיא זיכרון GPU אם ניתן למדוד אותו.
- שאלת ניתוח: האם המודל הגדול טוב יותר בכל משימה? באילו משימות הפער משמעותי, ובאילו כמעט לא? כיצד הדבר מתקשר לרעיון של scaling laws בלי לטעון שהניסוי הקטן "מאמת" חוק סקילינג?

8. חלק ה' - יעילות הסקה

מטרת החלק: לקשור בין רעיונות כגון KV cache, אורך הקשר, כמות הטוקנים שנוצרים ועלות ההסקה לבין מדידות בפועל.

- 1) בחרו prompt קבוע ובקשו מהמודל לייצר תשובות בארבעה אורכי output שונים.
 - 2) מדדו latency כולל, tokens/sec וזמן עד הטוקן הראשון אם הספרייה מאפשרת זאת.
 - 3) אם ניתן לשלוט ב-use_cache, השוו לפחות ניסוי אחד עם KV cache ובלעדיו. אם לא ניתן - הסבירו זאת ונתחו תיאורטית כיצד הייתם מצפים שהמדידה תשתנה.
 - 4) הציגו גרף אחד לפחות המתאר את הקשר בין מספר טוקנים לבין זמן ריצה או throughput.
- שאלת ניתוח: איזה חלק מהעלות קשור ל-prefill ואיזה ל-decoding? אין צורך במודל אנליטי מדויק; כן נדרשת פרשנות הנדסית של המדידות.

9. חלק ו' - Failure Forensics

מטרת החלק: לאסוף כשלים באופן שיטתי ולבנות taxonomy במקום להציג "דוגמאות מצחיקות".

- 1) מצאו לפחות 8 כשלונות אמיתיים של המודל מתוך הניסויים שביצעתם או מניסויים נוספים.
- 2) סווגו אותם ל-3 קטגוריות לפחות, כגון, hallucination, reasoning, instruction following, formatting, multilingual, long-context או numerical errors.
- 3) לכל קטגוריה הציגו לפחות דוגמה אחת, הסבר אפשרי והצעה לניסוי נוסף שהיה עוזר לאבחן את מקור הבעיה.
- 4) בחרו כשל אחד ובצעו "minimal pair": שינוי קטן בלבד ב-prompt או בקלט, ובדקו האם ההתנהגות משתנה.

10. דו"ח פורנזי מסכם

בסוף העבודה כתבו עמוד מסכם אחד שכותרתו "Forensic Profile". מטרתו אינה לחזור על התוצאות אלא לנסח תמונת מצב של המודל על בסיס הראיות שאספתם.

- מה המודל עושה טוב במיוחד?
- איפה נמצאות נקודות החולשה העיקריות?
- איזה trade-off מצאתם בין איכות, מהירות וזיכרון?
- איזו תכונה של המודל הופתעתם לגלות?
- איזו מסקנה שלכם היא חזקה, ואיזו עדיין ספקולטיבית? הסבירו למה.

11. מה מגישים

- מחברת Jupyter / Colab מלאה שניתן להריץ מתחילתה ועד סופה.
- דו"ח קצר של 5-7 עמודים, לא כולל נספחים, עם גרפים, טבלאות, תוצאות וניתוח.
- קובץ requirements.txt או תא פתיחה המציין גרסאות ספריות עיקריות.
- README קצר עם הוראות הרצה, שמות המודלים והערכת משאבי החומרה שנדרשו.
- נספח אופציונלי עם outputs מלאים; בגוף הדו"ח יש להציג רק דוגמאות הנחוצות לניתוח.

12. דרישות איכות ופרודוציביליות

- יש לתעד model ID מדויק, revision אם רלוונטי, dtype ופרמטרי generation.
- כאשר משתמשים בדגימה, יש לקבוע seed ולדווח עליו.
- אין להסתמך על תוצאה בודדת כאשר קיימת אקראיות משמעותית.
- גרפים וטבלאות צריכים לכלול כותרות וצירי מדידה ברורים.
- יש לשמור על הפרדה בין תוצאות אמפיריות, פרשנות והשערה.

13. מחוון הערכה

רכיב	משקל	מה נבדק
תכנון ניסויים ומתודולוגיה	20%	שליטה במשתנים, בחירת מדדים, reproducibility והצדקה של תכנון הניסוי.
ביצוע טכני	20%	קוד עובד, מדידות נכונות, שימוש תקין במודלים וב-tokenizer, תיעוד סביבת העבודה.
כיסוי נושאי הקורס	20%	חיבור ברור בין הניסויים לטוקניזציה, דקודינג, הקשר, סקיילינג ויעילות.
ניתוח והסקת מסקנות	25%	מסקנות מבוססות ראיות, זיהוי מגבלות, הימנעות מהסקת יתר וניתוח כשלים.
איכות הדו"ח והצגה	15%	בהירות, גרפים/טבלאות, מבנה, תמציתיות ויכולת לשחזר את העבודה.

14. בונוס (עד 5 נקודות)

- בחרו הרחבה אחת בלבד והציגו אותה באופן מסודר. הבונוס אינו מפצה על חוסרים בחלקי החובה.
- השוואה בין MHA/GQA או בין מודלים בעלי ארכיטקטורת attention שונה, אם ניתן לזהות ולהריץ אותם.
 - בדיקת quantization ברמות שונות והשפעתה על זיכרון, מהירות ואיכות.
 - בדיקת attention maps או hidden states לצורך אבחון תופעה שנצפתה, בלי לטעון ש-attention הוא "הסבר" מלא.
 - בניית dashboard קטן שמרכז את התוצאות והמדדים של המודל.

15. כללים והבהרות

- המטלה אישית.
- מותר להשתמש בכלי AI לצורכי תכנות, debugging ושיפור ניסוח, אך האחריות להבנת הקוד, הניסויים והמסקנות היא שלכם.
- אין צורך לאמן מודל מאפס ואין צורך לבצע fine-tuning. נושאים אלה יופיעו בהמשך הקורס.
- אין צורך להשתמש בנתונים רגישים או פרטיים. העדיפו נתונים סינתטיים או ציבוריים.

- במקרה של מגבלת חומרה, ניתן לצמצם את מספר הדוגמאות בניסוי לאחר אישור, אך אין לוותר על העיקרון הנבדק.

הקו המנחה - התוצאה החשובה של המטלה אינה "מי המודל הכי טוב", אלא היכולת לתכנן ניסוי שמבודד תופעה, למדוד אותה, ולנסח מסקנה זהירה שמחברת בין ההתנהגות הנצפית לבין העקרונות שנלמדו בקורס.